

单/双目深度估计研究进展与应用综述 (特邀)

胡海洋, 陈超平*, 高天沐, 韩宝恩, 杨云帆, 刘 毅, 武小军

(上海交通大学 航空电子综合与体系集成全国重点实验室, 上海 200240)

摘 要: 深度估计作为计算机视觉领域的核心基础任务,在自动驾驶、增强现实、机器人导航等领域具有重要应用价值。文中系统综述了单目与双目深度估计的技术演进、方法体系及其在三维显示等场景中的创新应用。单目方法通过端到端深度学习架构,如多尺度特征融合、注意力机制,突破传统几何先验限制,结合监督或自监督范式缓解数据依赖问题,但受限于尺度模糊性。双目技术依托立体匹配的几何约束,通过代价体积构建与三维卷积网络实现亚像素级视差计算,在动态场景鲁棒性上表现突出。两类技术通过语义几何协同优化形成互补,推动算法从局部特征匹配向全局三维感知升级。在三维显示领域,深度估计技术成为虚实融合的关键:单目方法支撑移动终端设备的实时空间拓扑重建,通过轻量化模型实现虚拟物体的物理遮挡与光照一致性渲染;双目技术为高精度全息投影与数字孪生提供毫米级深度支撑,实现动态光场重建。新兴技术如扩散模型和多教师蒸馏框架显著提升弱纹理区域的深度连续性,推动体积显示器渲染质量提升。文中进一步对比分析了主流数据集与评估指标的技术特性,指出未来研究需聚焦多传感器融合、轻量化边缘计算、跨模态评估基准构建及物理可逆渲染等方向。随着神经符号计算等范式的发展,深度估计技术将推动三维显示从几何重构向物理属性推理跃迁,最终实现“所见即所得”的沉浸式体验。

关键词: 深度估计; 计算机视觉; 机器学习; 三维显示

中图分类号: TP391.4 **文献标志码:** A **DOI:** 10.3788/IRLA20250157

引用格式: HU Haiyang, CHEN Chaoping, GAO Tianmu, et al. Recent progress in research and applications of monocular and binocular depth estimation (invited)[J]. *Infrared and Laser Engineering*, 2025, 54(7): 20250157.

胡海洋, 陈超平, 高天沐, 等. 单/双目深度估计研究进展与应用综述 (特邀)[J]. 红外与激光工程, 2025, 54(7): 20250157.

0 引 言

深度估计作为计算机视觉领域的核心基础任务,旨在从二维图像中恢复场景的三维几何信息,其技术突破对自动驾驶、增强现实、机器人导航等关键领域具有重要支撑作用。深度估计分为单目和双目两类,核心差异在于输入是单张图像还是立体图像对。单目方法早期依赖几何线索和统计模型,虽可解释性强,但面对复杂动态环境或弱纹理区域时精度受限。随着深度学习发展,基于卷积神经网络^[1-2]和 Transformer^[3-5]的端到端模型通过隐式学习图像与深度的关联,大幅提升了预测精度和场景适应能力,推

动技术从几何驱动转向数据与语义双重驱动。监督学习利用标注数据优化网络细节还原能力,但数据成本高的问题催生了自监督范式,通过图像对的光度一致性或视频动态连续性生成监督信号,降低数据依赖。视觉 Transformer 凭借全局注意力机制改善了远距离深度预测和边缘保持效果,但单目仍受尺度模糊性和动态物体处理能力不足的制约。双目方法通过模拟人眼立体视觉,利用视差直接计算绝对深度,传统双目算法依赖几何约束但易受弱纹理干扰。深度学习与立体匹配结合后,端到端网络通过代价体积构建和三维卷积实现亚像素级的视差估计。单目与双目的协同创新成为趋势,例如用语义信息优化立体匹

收稿日期:2025-03-10; 修订日期:2025-04-15

基金项目:工业和信息化部全国重点实验室种子基金项目 (GO0300164/001)

作者简介:胡海洋,男,硕士生,主要从事增强/虚拟现实、三维显示方面的研究。

导师(通讯作者)简介:陈超平,男,副研究员,博士,主要从事增强/虚拟现实、近眼显示、眼科学方面的研究。

配或引入几何约束,形成互补技术生态。文中系统梳理单目与双目深度估计的技术演进脉络,从方法分类、核心算法、数据集构建、评估体系及应用场景展开对比分析。文章介绍了单/双目深度估计中传统方法、机器学习模型与深度学习范式的技术突破,展望深度估计技术在三维显示、智能感知等领域的未来发展方向。文中旨在为研究者提供技术发展的全景视图,并为算法选型与工程化落地提供理论依据。

1 单目深度估计

1.1 方法分类与核心算法

单目深度估计技术可分为三大类:传统方法、基于机器学习的传统方法和深度学习方法,其中深度学习方法进一步细分为监督学习、无监督学习与半监督学习^[6-7]。

1.1.1 传统方法

传统单目深度估计方法的核心在于利用人类视觉启发式线索,通过图像中的几何特征反推三维结构。这类方法无需大规模数据训练,但依赖场景先验假设与物理模型约束。

一种方法是线性透视与大气散射法。线性透视基于物体尺寸随距离缩小的规律(如道路边缘汇聚效应),通过计算消失点与投影几何关系推断深度。监督学习方法,通过多尺度特征和马尔可夫随机场(MRF)模型,从单目图像中恢复非结构化户外场景(如森林、建筑)的深度图,其使用的深度特征向量如图 1 所示^[8]。图像块的深度特征包括其近邻和更远邻(更大尺度)的特征,每个块的相对深度特征使用滤波器输出的直方图。

大气散射则利用空气中颗粒物对光线散射导致的色彩衰减特性,结合 RGB 通道的亮度差异建立深度-色彩映射关系^[9]。该方法提供了从色彩衰减特性到几何深度的鲁棒推理。不过,该方法在极端天气或动态光源下的泛化能力仍面临挑战。

运动恢复结构(Structure from Motion, SFM)方法通过相机移动轨迹重建稀疏 3D 点云,核心步骤包括:特征匹配,即采用 SIFT/SURF 算法提取关键点并建立跨帧对应关系;对极几何优化,即通过基础矩阵




图 1 传统单目深度估计使用的深度特征向量^[8]

Fig.1 Depth feature used in traditional monocular depth estimation^[8]

(Fundamental Matrix) 估计相机位姿;光束法平差(Bundle Adjustment),通过非线性优化相机参数与 3D 点坐标,最小化重投影误差^[10]。


阴影恢复形状(Shape from Shading, SFS)法根据单幅图像的光照模型反推表面法向量,假设场景满足 Lambertian 反射模型且光源参数已知,通过迭代优化求解法向量场后积分得到深度图^[11]。该方法对噪声敏感且依赖精确光源参数,适用场景有限。

1.1.2 基于机器学习的传统方法

在深度学习兴起前,研究者尝试通过统计学习建立图像特征与深度的映射关系,主要分为参数化与非参数化两类。

马尔可夫随机场(Markov Random Field, MRF)是一种参数学习方法。将深度估计建模为能量最小化问题,定义一元势能项(局部特征与深度的关联)与二元势能项(相邻像素深度平滑性约束)。

数据驱动检索是一种非参数学习方法。从预构建的 RGBD 数据库中检索与输入图像场景相似的样本,通过特征匹配选择候选深度图,再通过加权融合生成最终结果^[12]。图 2 展示了该检索方法的基本流程,这是一种非参数深度转移方法,从单图像或视频中自动生成合理深度图,尤其适用于传统方法失效的场景。通过输入图像在数据库中找到匹配的候选图像,并对候选图像进行翘曲处理,使其与输入图像的结构相匹配,并使用全局优化程序对翘曲候选图像进行插值,从而得出输入图像的逐像素深度估计值。该方法依赖大规模数据库且泛化能力受限,但对特定场景(如室内布局)效果显著。


图2 基于机器学习的传统检索方法的深度估算流程^[12]Fig.2 Pipeline for traditional retrieval methods based on machine learning^[12]

1.1.3 深度学习方法

基于深度学习的单目深度估计通过端到端模型直接学习 RGB 图像到深度图的映射,突破了传统方法的场景假设限制,显著提升了预测精度与泛化能力。首先介绍监督学习方法。从网络架构上来看,EIGEN 等提出首个两阶段卷积网络,先通过全局粗估计网络获取场景结构,再利用局部细化网络优化细节^[13],图3展示了该两阶段卷积网络的架构。后续工作引入了残差连接(ResNet)与空洞卷积增强了模型的多尺度特征融合能力^[14]。DORN 将深度估计转化为有序回归问题,通过空间离散化缓解深度值分布不

均匀问题,显著提升了远距离区域的预测精度^[15]。

近年来, Vision Transformer(ViT)^[4,16-18] 被引入深度估计任务,例如 DPT^[19] 通过 ViT 的全局建模能力与高分辨率处理,结合卷积解码器的多尺度融合,在密集预测任务中实现了更精细、全局一致的预测效果,尤其在大规模数据下优势显著。如图4所示,DPT 通过提取非重叠斑块,然后对其扁平化表示进行线性投影,或应用 ResNet-50 特征提取器,将输入图像转换为标记(橙色)。在图像嵌入的基础上增加位置嵌入,并添加与补丁无关的读出标记(红色)。标记经过多个转换器阶段。最后将来自不同阶段的标记以

图3 单目深度估计网络架构:两阶段卷积网络^[13]Fig.3 Monocular depth estimation network architecture: two-stage convolutional network^[13]

多种分辨率 (绿色) 重新组合成类似图像的特征。融合模块 (紫色) 会逐步融合和上采样这些特征, 从而即可生成细粒度预测。未来 DPT 可扩展至更多任务 (如实例分割、光流估计), 并探索更高效的 Transformer 变体。近年来, 基于状态空间模型的视觉 Mamba 架构在深度估计领域展现出突破性潜力。Mambavision^[16] 作为首个融合 Mamba 与 Transformer 的混合视觉主干网络, 通过选择性状态机制实现了线性计算复杂度, 相较于传统 Transformer 的二次复杂度, 显著提升了高分辨率深度图处理的效率。实验验证表明, 该架构在动态场景深度估计任务中具有显著优势。

从损失函数的创新方面来看, 针对深度尺度模糊性问题, EIGEN 等提出的尺度不变误差 (Scale-Invariant Error) 通过归一化处理消除了全局尺度差异对损失计算的影响。之后, 为保留深度不连续区域的边缘结构, 一些研究设计了边缘感知平滑性损失 (Edge-Aware Smoothness Loss), 结合图像梯度加权约

束深度图的局部平滑性^[20]。

为解决深度标注数据稀缺问题, 无监督与自监督学习逐渐也被用到了深度估计问题中。研究者利用立体图像对或单目视频序列中的几何一致性作为监督信号, 实现无需真实深度标签的训练。一些方法利用率基于立体匹配的自监督学习。GARG 等人首次提出通过左右视图的视差合成目标视图, 以重建误差作为监督信号进行深度估计的方案^[21], 如图 5 所示, 其利用左右立体对图片的重建损失训练卷积神经网络并使用该网络进行视差预测, 从而完成单目深度估计。GODARD 等人进一步引入左右一致性约束与遮挡掩码, 提升视差预测的鲁棒性^[22]。Monodepth2 通过最小化多尺度光度重构误差 (Photometric Reconstruction Loss) 与视差平滑性损失, 实现了动态场景下的稳定训练^[23]。另一些方法关注单目视频中的动态一致性。ZHOU 等人提出将单目视频序列中的相机运动与物体运动解耦, 通过联合优化深度预测网络与姿态估计网络, 解决动态物体对自监督学习的干扰^[24]。ManyDepth 利用多帧时序信息构建代价体积 (Cost Volume), 通过 3D 卷积聚合时空特征, 缓解单帧模糊性问题^[25]。

多任务学习同样被用于单目深度估计。通过共享特征表示联合学习深度估计与其他视觉任务 (如语义分割、表面法线估计), 可提升模型对场景理解的全面性。EIGEN 等人首次提出多任务网络, 在深度估计分支与语义分割分支间共享低层特征, 并通过高层特征交互增强任务相关性。BTS 将表面法线估计作为辅助任务, 通过法线方向与深度梯度的几何一致性损失 (如正交性约束) 提升深度图的结构合理性^[26]。

还有方法尝试了结合传统几何约束与深度学习,




图 4 DPT 架构图^[19]

Fig.4 Architecture overview of DPT^[19]




图 5 以重建误差作为监督信号的自监督方法示意图^[21]

Fig.5 Schematic of the self-supervised method with reconstruction error as the supervisory signal^[21]

同样可提升模型的可解释性与泛化能力。CHEN 等人将条件随机场 (CRF) 作为 CNN 的后处理模块, 通过能量函数建模像素间深度依赖关系, 优化局部细节^[27]。AdaBins 将深度离散化为自适应区间, 结合可微渲染技术生成高分辨率深度图, 同时保持全局连续性^[28]。

图 6 展示了先进的单目深度估计算法结果和真实深度的对比, 直观上可以看到其已经十分接近真实深度。




图 6 ZoeDepth 实验结果同真实深度对比^[29]

Fig.6 Comparison of ZoeDepth with true depth^[29]

1.1.4 方法总结和对比

单目深度估计方法可划分为传统方法与深度学习方法两大范式。传统方法主要依赖几何线索与统计模型, 例如基于线性透视、运动恢复结构 (SFM) 或阴影恢复形状 (SFS) 的算法, 通过手工设计的特征与物理先验 (如消失点、光度一致性) 反推深度信息。这类方法无需训练数据, 但受限于场景假设的强约束, 在动态物体或弱纹理区域表现较差。传统方法的优势在于其物理可解释性与无监督特性, 适用于实时性要求高但精度需求较低的场景 (如无人机避障)。然而, 这类方法对动态物体和弱纹理区域的适应性差, 且难以生成稠密深度图。例如, SFM 依赖静态场景假设, 而 SFS 需精确的光源参数, 实际应用中局限性显著。

深度学习方法的兴起彻底改变了这一领域, 其核心思想是通过端到端网络直接学习从 RGB 图像到深度图的复杂映射。与监督学习不同, 自监督方法利用立体图像对或视频序列中的几何一致性生成伪标签,

避免了真实深度数据的标注依赖。此外, 多任务学习和混合模型通过融合多模态特征或传统几何约束, 进一步提升了模型的鲁棒性与可解释性。

监督学习方法在充足标注数据下可实现高精度稠密预测, 广泛应用于自动驾驶和 AR/VR 领域。但其性能高度依赖训练数据分布, 跨域泛化能力较弱 (如从室内到室外场景迁移时精度骤降), 且标注成本高昂。

自监督学习方法通过几何一致性信号 (如立体匹配或时序运动) 避免了标注需求, 适用于动态环境中的深度估计 (如车载摄像头视频流)。然而, 这类方法对光照变化敏感, 且在动态物体 (如行人、车辆) 存在时易因光度一致性假设失效而产生伪影。

多任务与混合模型通过联合学习或融合传统几何约束, 试图平衡数据驱动与物理可解释性。这类方法在复杂场景理解中表现优异, 但计算复杂度较高, 且需谨慎设计任务权重以避免性能冲突。

在实时嵌入式系统 (如移动机器人导航) 中, 传统方法因低计算开销仍具实用价值, 但其稀疏或粗糙的深度输出难以满足高精度需求。监督学习在高精度场景 (如医疗影像三维重建) 中表现突出, 但依赖特定领域标注数据, 难以泛化至未见过的环境。自监督学习在缺乏标注数据的动态场景 (如户外监控视频) 中具有潜力, 但对动态物体和光照变化的鲁棒性仍需提升。混合模型更适合复杂任务 (如自动驾驶中的多模态感知), 但其高计算成本限制了在资源受限设备上的部署。

单目深度估计技术虽已取得显著进展, 但在实际应用中仍面临动态场景建模、跨域泛化、实时性需求与多模态融合等核心挑战。未来研究需持续突破, 同时关注算法的可解释性与伦理安全, 推动单目深度估计技术在自动驾驶、机器人导航、AR/VR 等领域的规模化落地。

1.2 数据集与评估指标

单目深度估计技术的发展与数据集的演进密不可分。早期研究主要依赖合成数据与有限场景的真实标注数据, 例如 NYU Depth V2 作为室内场景的经典数据集, 通过激光扫描仪获取了 1449 对 RGB-D 图像, 覆盖办公室、卧室等多种室内环境, 成为模型训练与验证的重要基准^[30]。而户外场景的研究则依赖于

KITTI 数据集,其通过多传感器融合(如激光雷达、双目相机)采集道路场景的深度信息,支持多任务标注(如目标检测、光流估计),推动了自动驾驶领域的算法进步^[31-32]。为缓解真实数据标注成本高的问题,虚拟数据集如 vKITTI 应运而生,通过渲染技术生成不同天气与视角的合成图像,增强了模型对光照变化的鲁棒性^[33]。近年来,数据集的构建更注重多样性与实用性,例如 DA-2 K 采用稀疏深度标签与自动掩模技术,覆盖复杂场景并减少人工标注负担^[34]; Kaggle 发布的视点变化数据集则通过单应性变换与目标检测生成伪标签,量化了相机位姿对深度估计的影响,为模型泛化性评估提供了新工具^[35]。MiDaS 提出通过混合多个 RGBD 数据集(如 KITTI、NYUv2 等)训练模型,以提升跨数据集的零样本泛化能力,并从 3D 电影中提取相对深度数据,扩展训练数据多样性^[36]。

在评估指标方面,单目深度估计的量化分析主要围绕误差度量与精度阈值展开。绝对相对误差(AbsRel)和均方根误差(RMSE)作为核心误差指标,分别衡量预测深度与真实值的相对偏差与绝对偏差,其中 RMSE 对远距离误差敏感,而 AbsRel 更关注整体一致性。对数误差(RMSE log)通过压缩深度尺度缓解长尾分布的影响,平方相对误差(SqRel)则放大大误差区域的惩罚,适用于对异常值敏感的场景。此外,阈值准确率统计预测值与真值比例落在指定区间的像素占比,直观反映模型的局部一致性能力。值得注意的是,尺度无关对数误差(SILog)通过分离尺度与形状误差,解决了单目深度估计的尺度模糊性问题,成为跨数据集评估的重要补充。然而,现有指标仍难以全面反映复杂场景下的模型表现,例如动态物体边缘的锐度、弱纹理区域的连续性等,这促使研究者结合可视化分析与人工评估进行综合判断。

未来,随着多模态传感器融合与生成式 AI 技术的发展,数据集的构建将更注重真实性与多样性平衡,例如结合神经辐射场生成高保真合成数据,或利用联邦学习框架保护隐私的同时扩展数据来源。评估体系则需引入语义一致性、物理合理性等高层语义指标,以推动单目深度估计从几何重建向场景理解深化。

1.3 应用场景

单目深度估计在三维显示场景下的应用正随着

技术的突破而不断拓展,其核心在于通过单张 RGB 图像精准推测深度信息,为虚拟与现实世界的融合提供了关键支持。在增强现实(AR)和虚拟现实(VR)领域,单目深度估计技术能够实时生成场景的深度图,使虚拟对象能够根据真实环境的几何结构自适应调整位置和光照,例如在 AR 眼镜中,虚拟物品可以更自然地“贴合”桌面或墙壁的曲面,显著提升用户的沉浸感。该类技术还被应用于全息显示终端,例如斯坦福研究团队提出的神经网络参数化平面到多平面波传播模型,通过单目深度估计生成的深度图指导三维全息图合成,同时结合物理光学特性与深度学习算法,有效减少了传统全息显示中的散斑噪声与离焦模糊^[37]。

在三维内容生成方面,单目深度估计为影视制作和游戏开发提供了高效工具。通过从单张图片推断深度,可以快速构建场景的三维模型并渲染逼真的光影效果,例如 Metric3D v2 算法能够直接生成高精度的 3D 点云,支持单帧图像的即时三维重建,其精度甚至足以替代部分物理传感器^[38]。这种技术还被用于文化遗产保护,例如对历史文物进行非接触式三维扫描,避免传统测量可能造成的损伤,同时生成可用于数字博物馆或虚拟修复的精细模型。

此外,在消费电子领域,单目深度估计推动了体积显示器和智能设备的革新。例如,苹果 Vision Pro 等头显设备利用该技术实时分析用户周围环境的深度,实现虚拟对象与物理空间的动态交互;而 MARIGOLD^[39]等基于扩散模型的算法,则通过生成高质量深度图,为计算摄影中的散景效果、动态光照调整提供支持,使手机拍摄的 2D 照片也能转换为立体视觉内容。最新技术如 Distill Any Depth^[40]通过多教师模型蒸馏框架,仅需少量无标签数据即可提升深度估计的鲁棒性,进一步降低了三维显示技术对标注数据的依赖,使其在数据匮乏场景(如考古现场或偏远地区)中更具实用性。这些进展共同推动着三维显示从专业领域向大众化应用渗透,为未来智能终端的交互方式开辟了新的可能性。

2 双目深度估计

单目深度估计实现了从二维图像到深度信息的映射,但其固有局限性——尺度模糊性和几何先验依

赖——始终制约着其在动态场景与高精度应用中的可靠性。为突破这一瓶颈,双目深度估计通过引入立体几何约束,将深度求解转化为视差计算问题,从根本上解决了尺度不确定性。近年来,随着深度学习与立体视觉的深度融合(如端到端立体匹配网络),双目方法在保持几何一致性的同时,进一步提升了复杂场景下的泛化能力,标志着三维感知技术从单目“经验驱动”到双目“几何数据驱动”的转变。下面将介绍双目深度估计技术的研究情况。

2.1 方法分类与核心算法

双目深度估计作为三维视觉感知的核心技术,通过模拟人类双眼视差感知机制,从左右视角图像中恢复场景的三维几何信息。双目深度估计算法的方法体系可划分为传统匹配算法与深度学习模型两大技术路径^[41-42]。

2.1.1 传统匹配方法

传统方法以几何匹配原理为核心,通过构建视差与深度的几何映射关系实现三维感知。早期算法如

块匹配 (Block Matching) 通过滑动窗口计算左右图像局部区域的相似性(如 SAD、SSD),但其在弱纹理区域易产生匹配歧义,且难以生成稠密深度图。BM 算法通过动态调整窗口大小与惩罚系数优化视差平滑性,而 SGBM 算法引入半全局能量最小化策略,结合多路径动态规划增强遮挡区域鲁棒性^[43],具体流程如图 7 所示。其流程首先对输入图像进行去噪和亮度归一化预处理,随后在每个像素的预设视差范围内(如 0~128)通过 BT 方法计算局部块匹配代价。接着沿多个方向(通常 8 或 16 个)执行动态规划,聚合路径上的匹配代价形成全局平滑约束的代价,再通过胜者全取策略确定初步视差值。后处理阶段采用亚像素插值提升精度,结合唯一性检验、左右一致性检查和邻域插值消除遮挡区域异常值并填补空洞。其他一些非局部算法如动态规划与图割通过全局能量函数建模视差连续性约束,显著提升遮挡场景的匹配精度,但硬件加速难度大,难以满足嵌入式部署需求^[44]。




图 7 SGBM 算法流程示意图

Fig.7 SGBM algorithm processing flowchart

2.1.2 深度学习方法

深度学习技术的引入彻底重构了双目深度估计的技术框架。端到端网络架构通过隐式学习特征表达与视差回归的复杂映射,突破了传统方法的性能瓶颈。根据技术演进脉络,深度双目方法可分为四代创新:基于相关性的匹配网络、代价体积优化网络、Transformer 架构网络以及轻量化实时网络。早期研究突破传统匹配代价计算方式,通过卷积网络实现特征表达与相似性度量的联合学习。DispNetC 提出全卷积编解码架构,通过构建相关性金字塔实现多尺度

匹配,其核心创新在于构建多尺度相关性金字塔,采用收缩-扩张结构,通过 5 层卷积提取左右图像的高维特征,并下采样至 1/4 分辨率以降低计算量,同时利用反卷积层逐步上采样,结合跳跃连接融合底层细节特征,最终输出全分辨率视差图。首次将运行速度提升至实时水平(30 FPS),但精度受限于浅层网络的特征表达能力^[45]。代价体积优化网络通过构建三维/四维代价体积(Cost Volume)实现全局上下文感知的立体匹配,标志着深度学习双目方法的成熟。PSMNet 开创性地提出金字塔立体匹配网络,利用空间金字塔

池化(SPP)融合多尺度特征,结合堆叠沙漏 3D 卷积优化代价体,显著提升复杂场景的视差估计一致性^[46]。图 8 展示了 PSMNet 的架构概览。首先,左右输入立体图像被送入两个权重共享网络,包括一个用于计算特征图的 CNN 和一个通过连接来自不同大小子区域的表征来收集特征的 SPP 模块,以及一个用于特征融合的卷积层。然后利用左右图像特征形成 4D 代价体,再将其输入 3D CNN 进行代价正则化和回归。其创新主要在于空间金字塔池化(SPP)模块和堆叠沙漏 3D CNN,首先使用残差块提取左右图像特征,结合扩张卷积(Dilated Convolution)扩大感受野,利用 SPP 对特征图进行多尺度平均池化。GC-Net 则引入全局

上下文嵌入层,通过三维卷积聚合全局特征增强匹配鲁棒性^[47]。针对传统相关方法特征对齐不足的问题,代价体方案通过特征图错位匹配构建四维代价体,结合三维卷积实现跨通道深度融合,但计算量激增导致实时性受限。为突破卷积网络的局部感受野限制,Vision Transformer 被引入立体匹配任务,实现全局特征交互与长程依赖建模。例如 STTR 通过交叉注意力层建模长程依赖,有效解决重复纹理区域的匹配歧义,但其训练收敛难度与算子部署效率仍为瓶颈^[48]。也有一些研究面向自动驾驶与移动端设备需求,研究重点在于精度、速度和功耗的平衡优化。




图 8 PSMNet 架构概览^[46]

Fig.8 Architecture overview of PSMNet^[46]

2.2 数据集与评估指标

双目深度估计的性能验证高度依赖多样化的数据集与科学化的评价体系。随着算法从传统几何匹配向深度学习范式演进,数据集的设计与评估指标的选择亦呈现多维度、多场景的精细化趋势。双目深度估计数据集可分为自动驾驶场景、合成仿真场景、室内场景及特殊场景四大类,其设计需平衡标注精度、场景多样性与数据规模^[29]。

自动驾驶场景数据集以 KITTI 系列(2012/2015)为代表,提供街景双目图像与稀疏激光雷达标注,其优势在于真实道路场景覆盖,但存在分辨率低(1242×375)、动态目标标注稀疏的局限^[32]。ApolloScape 与 Argoverse 2 进一步扩展数据规模,前者提供 3130×960 高分辨率双目图像与稠密点云标注,后者引入多城市(奥斯汀、迈阿密等)跨季节数据,支持域适应研究^[49-50]。下面介绍合成仿真数据集。SceneFlow 通过

渲染生成 35454 组双目图像与稠密视差图,涵盖飞行物体、单目车流等复杂动态场景,但其合成数据与真实场景的域差距 (Domain Gap) 可能影响模型泛化能力^[51]。再介绍室内场景数据集。Middlebury Stereo 提供高精度室内双目图像,分辨率达 3000×2000,适用于算法细节恢复能力评估^[52]。近年来,面向复杂感知条件的特殊挑战数据集不断涌现。ETH3D Stereo Benchmark 作为高精度室内外场景数据集,提供毫米级激光扫描真值,包含了混合光照条件,动态反射表面,多季节室外场景。TartanAir 则通过合成数据生成技术构建了涵盖极端运动模糊,光照突变等挑战性场景的立体序列,可模拟镜头污损、雨雪噪声等 68 种干扰因素。

双目深度估计的评价指标需兼顾几何精度、计算效率与场景适应性,主要分为像素级误差度量与任务导向型指标两类。像素级误差度量包括端点误差, D1-all 和尺度不变对数误差 (SILog)。端点误差计算视差图的绝对误差均值,反映全局匹配精度。D1-all 统计误匹配像素占比 (视差误差>3 pixel 或 5% 真值),常用于自动驾驶数据集评测,其中误匹配像素的判定采用双阈值准则:对于非遮挡区域像素,若视差估计值与真值的绝对或相对误差大于对应的阈值,即判定为误匹配。SILog 通过对数变换解耦尺度误差,适用于跨域泛化评估。总体来说双目更关注视差计算的几何一致性,单目因缺乏真实深度依赖相对误差与尺度不变性指标。双目深度估计的任务导向型指标包括实时性 (FPS) 和边缘保持度 (Edge Preservation Indicator, EPI)。其中 EPI 量化深度图与 RGB 边缘对齐,用于 AR/VR 场景。

2.3 和单目深度估计的比较

单目与双目深度估计的核心差异体现在几何约束的获取方式和数据标注依赖度上。单目方法仅依靠单张图像的语义先验 (如物体尺寸、遮挡关系、纹理梯度) 和场景理解,通过端到端网络学习图像到深度的非线性映射。由于缺乏物理视差,其深度估计存在固有尺度模糊性,需要通过相对误差指标 (如 AbsRel、RMSE log) 补偿全局深度偏差。例如,单目模型在弱纹理区域 (如白墙或天空) 可通过语义推理弥补几何信息缺失,但这种依赖导致其远距离误差随距离呈指数增长。相比之下,双目系统基于左右视图

的像素匹配计算视差,结合相机基线长度与焦距参数直接推导绝对深度,使得几何精度可达厘米级。实验数据显示,双目系统的误匹配占比 D1-all 较低,边缘保持度 (EPI) 指标验证了其深度图与 RGB 图像的高精度对齐特性。

从数据依赖角度看,单目监督学习需依赖 NYU Depth、KITTI 等标注数据集,而无监督方法需借助视频序列或双目对生成伪标签。而双目方法仅需相机标定参数,无需深度真值,但对双目相机的外参标定误差极其敏感,1% 的基线偏差可导致深度误差放大 10 倍。实际应用中,单目系统凭借单摄像头部署优势,广泛应用于手机、无人机等轻量化设备,而双目系统在自动驾驶近距避障等场景具有不可替代性,其动态物体鲁棒性显著优于单目方法。

发展趋势上,单目技术正通过多模态融合 (如 ZoeDepth 联合语义分割与 IMU 时序数据^[29]) 和无监督创新 (如 Marigold 扩散模型^[39]) 提升跨域泛化能力。双目方向则聚焦轻量化设计,同时探索事件相机解决运动模糊下的视差计算难题。两类技术未来将向多传感器协同演进,例如 LiDAR 辅助标定可有效缓解单目尺度模糊性,而双目与 ToF 相机的融合能突破传统几何计算的范围限制。

2.4 应用场景

双目深度估计在三维显示场景下的应用核心在于通过模拟人类双眼的立体视觉机制,将二维图像转化为具有深度信息的三维模型,从而增强沉浸感和交互的真实性。其技术基础源于双目相机的视差计算,这一过程不仅能够还原物体的三维几何结构,还可通过稠密深度图实现高精度的空间重建,例如在虚拟现实 (VR) 中构建动态环境或在增强现实 (AR) 中实现虚实融合的精准叠加。

在 3D 电影与全息显示领域,双目深度估计通过生成左右眼差异图像,配合偏振或主动快门式 3D 眼镜,使观众感知到物体的前后层次。例如,ZED 2i 双目相机结合地平线开发的 StereoNet 算法^[53],实时输出视差数据并通过 BPU 加速渲染,能够在动态场景中呈现细腻的深度细节,如光线变化区域的精准区分。这种技术还被用于全景影院的无框显示设计,通过消除传统屏幕边界限制,利用空气透视和重叠暗示增强立体感。

然而,实际应用中仍需克服硬件校准的稳定性问题。双目系统要求摄像头在长期使用中保持严格的共面行对齐,微小的机械偏移会导致深度计算误差。此外,低纹理区域(如大面积纯色墙面)的特征匹配困难可能引发“黑洞”伪影,需依赖深度学习模型的多尺度损失函数优化。未来,随着 Transformer 架构的引入,全局感受野的扩展将进一步改善复杂场景下的深度一致性,例如 DPT 模型^[19]通过多尺度结构同时保证局部精度与全局连贯性。尽管双目系统依赖精确的相机标定参数,但近年来动态在线标定技术的突破显著提升了系统鲁棒性。基于特征流形学习的自标定算法和更前沿的惯性-视觉融合方案等技术进步有效缓解了传统双目系统对初始标定精度的敏感性,推动双目视觉从实验室精密测量向户外动态场景的规模化落地。

在工业设计与医疗成像中,双目深度估计支持高分辨率三维重建。例如,飞桨的 PaddleDepth 套件^[54]通过激光雷达稀疏数据补全和图像超分辨技术,生成可用于手术导航的稠密器官模型。而在智能制造中,双目系统可实时捕捉机械臂操作轨迹,结合深度图解析实现毫米级精度的自动化装配。这些应用不仅依赖于算法优化,还需结合传感器融合(如 ToF 设备)弥补单一模态的局限性,形成多维度感知体系。通过持续的技术迭代,双目深度估计正成为连接虚拟与现实空间的关键桥梁。

3 结 论

单目与双目深度估计技术近年来不断发展。单目方法通过端到端深度学习架构(如多尺度特征融合、注意力机制)实现无需几何先验的深度推理,显著提升了对弱纹理区域的语义理解能力,代表性工作通过引入虚拟法线约束和概率建模缓解了尺度模糊性问题。双目技术则围绕立体匹配核心任务展开革新,基于代价体构建的 3D 卷积网络优化了视差估计精度,而动态场景下的匹配鲁棒性通过光流-视差联合学习框架得到增强。近年来,两类技术的协同创新尤为突出,单目分支通过语义分割多任务学习为双目匹配提供场景先验,双目系统则以几何一致性损失引导单目模型实现自监督尺度恢复,形成双向知识迁移的闭环优化。此外,神经辐射场与 Transformer 架

构的引入,推动了多视角几何重建与全局上下文建模的深度融合,标志着算法从局部特征匹配向整体三维感知的范式升级。

在三维显示领域,深度估计技术正成为虚实融合的关键使能者。单目方法凭借轻量化优势,将推动移动端三维交互设备的普及。例如 AR 眼镜^[55]可通过实时深度感知实现虚拟物体的物理遮挡与光照一致性渲染。Vision Pro 等头显设备利用单目深度重构空间拓扑以增强虚实融合沉浸感。双目技术则为高精度三维重建提供支撑,在数字孪生、全息投影等场景中,其亚像素级视差计算能力可生成毫米级精度的立体模型,配合神经辐射场实现动态场景的光场重建。值得关注的是,基于扩散模型的深度生成技术通过提升弱纹理区域的深度连续性,显著改善了体积显示器的动态渲染质量,而多教师蒸馏框架则降低了三维内容生成对标注数据的依赖,加速了文化遗产数字化等长尾场景的应用落地。

未来研究可能聚焦方向包括:多传感器融合框架下的自适应深度估计^[56];轻量化模型设计与边缘计算优化;跨域评估基准构建以提升复杂环境适应性;算法可解释性增强与物理规律耦合。随着三维视觉技术持续突破,单/双目深度估计将在智能制造、自动驾驶等领域推动 AI 向三维认知演进。

参考文献:

- [1] LECUN Y, BOTTOU L, BENGIO Y, et al. Gradient-based learning applied to document recognition [J]. *Proceedings of the IEEE*, 1998, 86(11): 2278-2324.
- [2] KRIZHEVSKY A, SUTSKEVER I, HINTON G E. ImageNet classification with deep convolutional neural networks [J]. *Communications of the ACM*, 2017, 60(6): 84-90.
- [3] VASWANI A, SHAZEER N, PARMAR N, et al. Attention is all you need [J]. *arXiv*: 1706.03762cs, 2017.
- [4] DOSOVITSKIY A, BEYER L, KOLESNIKOV A, et al. An image is worth 16×16 words: Transformers for image recognition at scale [J]. *arXiv*: 2010.11929cs, 2020.
- [5] CORDONNIER J-B, LOUKAS A, JAGGI M. On the relationship between self-attention and convolutional layers [J]. *arXiv*: 1911.03584cs, 2019.
- [6] ARAMPATZAKIS V, PAVLIDIS G, MITIANOUDIS N, et al. Monocular depth estimation: A thorough review [J]. *IEEE Transactions on Pattern Analysis and Machine Intelligence*,

- 2023, 46(4): 2396-2414.
- [7] KHAN F, SALAHUDDIN S, JAVIDNIA H. Deep learning-based monocular depth estimation methods—a state-of-the-art review [J]. *Sensors*, 2020, 20(8): 2272.
- [8] SAXENA A, CHUNG S, NG A. Learning depth from single monocular images [J]. *Advances in Neural Information Processing Systems*, 2005: 1161-1168.
- [9] NARASIMHAN S G, NAYAR S K. Contrast restoration of weather degraded images [J]. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 2003, 25(6): 713-724.
- [10] SNAVELY N, SEITZ S M, SZELISKI R. Photo tourism: Exploring photo collections in 3D [J]. *ACM Transactions on Graphics*, 2006, 25(3): 835-846.
- [11] ZHANG R, TSAI P-S, CRYER J E, et al. Shape-from-shading: A survey [J]. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 1999, 21(8): 690-706.
- [12] KARSCH K, LIU C, KANG S B. Depth transfer: Depth extraction from video using non-parametric sampling [J]. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 2014, 36(11): 2144-2158.
- [13] EIGEN D, PUHRSCHE C, FERGUS R. Depth map prediction from a single image using a multi-scale deep network [J]. *Advances in Neural Information Processing Systems*, 2014, 27.
- [14] LAINA I, RUPPRECHT C, BELAGIANNIS V, et al. Deeper depth prediction with fully convolutional residual networks[C]//Proceedings of the 2016 Fourth International Conference on 3D Vision, 2016: 239-248.
- [15] FU H, GONG M, WANG C, et al. Deep ordinal regression network for monocular depth estimation[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2018: 2002-2011.
- [16] HATAMIZADEH A, KAUTZ J. Mambavision: A hybrid mamba-transformer vision backbone [J]. *arXiv*: 2407.08083cs, 2024.
- [17] LIU Z, LIN Y, CAO Y, et al. Swin transformer: Hierarchical vision transformer using shifted windows[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision, 2021: 10012-10022.
- [18] LIU Y, ZHANG Y, WANG Y, et al. A survey of visual transformers [J]. *arXiv*: 2111.06091cs, 2023.
- [19] RANFTL R, BOCHKOVSKIY A, KOLTUN V. Vision transformers for dense prediction[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision, 2021: 12179-12188.
- [20] LI B, DAI Y, HE M. Monocular depth estimation with hierarchical fusion of dilated cnns and soft-weighted-sum inference [J]. *Pattern Recognition*, 2018, 83: 328-339.
- [21] GARG R, BG V K, CARNEIRO G, et al. Unsupervised cnn for single view depth estimation: Geometry to the rescue[C]//Computer Vision—ECCV 2016: 14th European Conference, Amsterdam, The Netherlands, October 11-14, 2016, Proceedings, Part VIII 14, 2016: 740-756.
- [22] GODARD C, MAC AODHA O, BROSTOW G J. Unsupervised monocular depth estimation with left-right consistency[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2017: 270-279.
- [23] GODARD C, MAC AODHA O, FIRMAN M, et al. Digging into self-supervised monocular depth estimation[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision, 2019: 3828-3838.
- [24] ZHOU T, BROWN M, SNAVELY N, et al. Unsupervised learning of depth and ego-motion from video[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2017: 1851-1858.
- [25] WATSON J, MAC AODHA O, PRISACARIU V, et al. The temporal opportunist: Self-supervised multi-frame monocular depth[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2021: 1164-1174.
- [26] LEE J H, HAN M-K, KO D W, et al. From big to small: Multi-scale local planar guidance for monocular depth estimation [J]. *arXiv*: 1907.10326cs, 2019.
- [27] CHEN L-C, PAPANDREOU G, KOKKINOS I, et al. Deeplab: Semantic image segmentation with deep convolutional nets, atrous convolution, and fully connected crfs [J]. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 2017, 40(4): 834-848.
- [28] BHAT S F, ALHASHIM I, WONKA P. Adabins: Depth estimation using adaptive bins[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2021: 4009-4018.
- [29] BHAT S F, BIRKL R, WOFK D, et al. Zoedepth: Zero-shot transfer by combining relative and metric depth [J]. *arXiv*: 2302.12288cs, 2023.
- [30] SILBERMAN N, HOIEM D, KOHLI P, et al. Indoor segmentation and support inference from rgbd images[C]//Proceedings of the Computer Vision—ECCV 2012: 12th European Conference on Computer Vision, Florence, Italy, October 7-13, 2012, Proceedings, Part V 12, 2012: 746-760.
- [31] GEIGER A, LENZ P, URTASUN R. Are we ready for autonomous driving? the kitti vision benchmark suite[C]//Proceedings of the Conference on Computer Vision and Pattern Recognition, 2012: 3354-3361.

- [32] GEIGER A, LENZ P, STILLER C, et al. Vision meets robotics: The kitti dataset [J]. *The International Journal of Robotics Research*, 2013, 32(11): 1231-1237.
- [33] GAIDON A, WANG Q, CABON Y, et al. Virtual worlds as proxy for multi-object tracking analysis[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2016: 4340-4349.
- [34] YANG L, KANG B, HUANG Z, et al. Depth anything: Unleashing the power of large-scale unlabeled data[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2024: 10371-10381.
- [35] RANFTL R, LASINGER K, HAFNER D, et al. A new dataset for monocular depth estimation under viewpoint shifts [J]. *arXiv*: 2409.17851cs, 2024.
- [36] RANFTL R, LASINGER K, HAFNER D, et al. Towards robust monocular depth estimation: Mixing datasets for zero-shot cross-dataset transfer [J]. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 2020, 44(3): 1623-1637.
- [37] CHOI S, GOPAKUMAR M, PENG Y, et al. Neural 3D holography: Learning accurate wave propagation models for 3D holographic virtual and augmented reality displays [J]. *ACM Transactions on Graphics*, 2021, 40(6): 1-12.
- [38] HU M, YIN W, ZHANG C, et al. Metric3d v2: A versatile monocular geometric foundation model for zero-shot metric depth and surface normal estimation [J]. *ACM Transactions on Graphics*, 2024, 46(12): 10579-10596.
- [39] KE B, OBUKHOV A, HUANG S, et al. Repurposing diffusion-based image generators for monocular depth estimation[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2024: 9492-9502.
- [40] HE X, GUO D, LI H, et al. Distill any depth: Distillation creates a stronger monocular depth estimator [J]. *arXiv*: 2502.19204cs, 2025.
- [41] LAGA H, JOSPIN L V, BOUSSAID F, et al. A survey on deep learning techniques for stereo-based depth estimation [J]. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 2020, 44(4): 1738-1764.
- [42] GHOSH S, GALLEGU G. Event-based stereo depth estimation: A survey [J]. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 2025: 1-20.
- [43] HIRSCHMULLER H. Stereo processing by semiglobal matching and mutual information [J]. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 2007, 30(2): 328-341.
- [44] BARRON J T, ADAMS A, SHIH Y, et al. Fast bilateral-space stereo for synthetic defocus[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2015: 4466-4474.
- [45] MAYER N, ILG E, HAUSSE P, et al. A large dataset to train convolutional networks for disparity, optical flow, and scene flow estimation[C]//Proceedings of the Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2016: 4040-4048.
- [46] CHANG J-R, CHEN Y-S. Pyramid stereo matching network[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2018: 5410-5418.
- [47] KENDALL A, MARTIROSYAN H, DASGUPTA S, et al. End-to-end learning of geometry and context for deep stereo regression[C]//Proceedings of the IEEE International Conference on Computer Vision, 2017: 66-75.
- [48] LI Z, LIU X, DRENNOW N, et al. Revisiting stereo depth estimation from a sequence-to-sequence perspective with transformers[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision, 2021: 6197-6206.
- [49] WILSON B, QI W, AGARWAL T, et al. Argoverse 2: Next generation datasets for self-driving perception and forecasting [J]. *arXiv*: 2301.00493cs, 2023.
- [50] HUANG X, CHENG X, GENG Q, et al. The apollo-scope dataset for autonomous driving[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition Workshops, 2018: 954-960.
- [51] MAYER N, ILG E, HAUSSE P, et al. A large dataset to train convolutional networks for disparity, optical flow, and scene flow estimation[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2016: 4040-4048.
- [52] SCHARSTEIN D, SZELISKI R. High-accuracy stereo depth maps using structured light[C]//2003 IEEE Computer Society Conference on Computer Vision and Pattern Recognition, 2003.
- [53] KHAMIS S, FANELLO S, RHEMANN C, et al. Stereonet: Guided hierarchical refinement for real-time edge-aware depth prediction[C]//Proceedings of the European Conference on Computer Vision, 2018: 573-590.
- [54] PaddlePaddle. PaddleDepth: A Toolkit for Depth Information Argumentation[CP/OL]. GitHub, 2023(2023-05-03)[2025-07-18]. <https://github.com/PaddlePaddle/PaddleDepth>.
- [55] CHEN C P, WU X, WANG J, et al. Penta-channel waveguide-based near-eye display with two-dimensional pupil expansion [J]. *Displays*, 2025, 88: 102999.
- [56] GAO T, ZOU D, CHEN C P, et al. Online lane mapping based on multi-sensor SLAM and Catmull-Rom splines [J]. *Measurement Science and Technology*, 2025, 36: 026318.

Recent progress in research and applications of monocular and binocular depth estimation (*invited*)

HU Haiyang, CHEN Chaoping*, GAO Tianmu, HAN Baoen, YANG Yunfan, LIU Yi, WU Xiaojun

(State Key Laboratory of Avionics Integration and Aviation System-of-Systems Synthesis, Shanghai Jiao Tong University, Shanghai 200240, China)

Abstract:

Significance Depth estimation, as a foundational task in computer vision, plays a critical role in enabling technologies such as autonomous driving, augmented/virtual reality (AR/VR), and robotic navigation. By recovering 3D geometric information from 2D images, it bridges the gap between visual perception and spatial understanding, serving as the backbone for immersive 3D displays and intelligent systems. Monocular and stereo depth estimation represent two complementary paradigms: the former leverages semantic reasoning and data-driven learning to infer depth from single images, while the latter relies on geometric constraints from stereo pairs to achieve absolute depth recovery. The synergy between these approaches has driven advancements in 3D scene reconstruction, dynamic object interaction, and real-time rendering, making depth estimation indispensable for applications ranging from holographic projection to digital twins.

Progress The evolution of monocular depth estimation has been marked by a shift from heuristic geometric priors to deep learning architectures. Early methods, such as linear perspective and structure-from-motion (SFM), relied on handcrafted features like vanishing points and sparse 3D point clouds but struggled with textureless regions and dynamic scenes. The introduction of convolutional neural networks (CNNs) revolutionized the field, enabling end-to-end frameworks like Eigen et al.'s two-stage network and DORN's ordinal regression model to predict dense depth maps with unprecedented accuracy. Vision Transformers (ViTs), exemplified by DPT, further enhanced global context modeling through self-attention mechanisms, improving edge preservation and long-range consistency. Self-supervised paradigms, such as Monodepth2 and ManyDepth, bypassed the need for labeled data by exploiting photometric consistency from stereo pairs or video sequences, while hybrid models like AdaBins integrated adaptive depth discretization and traditional geometric constraints for refined outputs. Stereo depth estimation, rooted in the principles of binocular vision, has similarly transitioned from classical algorithms to deep learning frameworks. Traditional methods like semi-global matching (SGBM) employed dynamic programming and energy minimization for disparity computation but faced challenges in occluded or low-texture areas. Deep stereo networks, such as PSMNet and GC-Net, redefined the field through cost volume construction and 3D convolutions, enabling sub-pixel disparity estimation and robustness to illumination variations. Transformer-based architectures like STTR introduced cross-attention mechanisms to resolve ambiguities in repetitive textures, while lightweight designs (e.g., StereoNet) optimized real-time performance for embedded systems. Datasets such as KITTI, SceneFlow, and ApolloScape have been instrumental in benchmarking progress, with recent efforts like DA-2K and MiDaS addressing cross-domain generalization through sparse annotations and multi-dataset fusion. In 3D display applications, monocular methods excel in mobile AR/VR devices by enabling real-time spatial reconstruction and occlusion-aware rendering. For instance, Apple Vision Pro leverages monocular depth estimation to dynamically align virtual objects with physical environments, while diffusion models like Marigold enhance depth continuity in weak-texture regions for photorealistic volumetric displays.

Stereo techniques, on the other hand, underpin high-precision holography and industrial digital twins, where millimeter-level accuracy is critical. Innovations such as neural radiance fields (NeRF) and multi-teacher distillation frameworks (e.g., Distill Any Depth) further bridge the gap between geometric reconstruction and semantic understanding, enabling dynamic light field synthesis and resource-efficient deployment.

Conclusions and Prospects Monocular and stereo depth estimation have evolved into mature yet rapidly advancing fields, each addressing unique challenges and application demands. Monocular methods, with their lightweight deployment and semantic reasoning capabilities, are ideal for edge devices and dynamic environments, while stereo systems provide unmatched geometric precision for mission-critical tasks like autonomous navigation. Future research must prioritize multi-sensor fusion (e.g., LiDAR, IMU) to mitigate monocular scale ambiguity and enhance robustness in occluded scenes. Lightweight architectures and neuromorphic hardware integration will accelerate real-time performance, enabling seamless integration into consumer electronics and IoT devices. Cross-modal benchmarks and physics-aware rendering techniques are needed to evaluate and improve depth consistency under varying illumination and motion conditions. Emerging paradigms, such as neural symbolic computing and event-based vision, promise to unify geometric reconstruction with physical reasoning, paving the way for "what-you-see-is-what-you-get" immersive experiences. As depth estimation transitions from academic research to industrial standardization, collaborative efforts across disciplines will be essential to harness its full potential in shaping the future of 3D visualization and intelligent perception.

Key words: depth estimation; computer vision; machine learning; 3D display

Funding projects: Ministry of Industry and Information Technology State Key Laboratory Seed Fund (GO0300164/001)